LAPORAN UTS

SEGMENTASI PROFIL SISWA PADA JARINGAN SOSIAL MENGGUNAKAN CLUSTERING

Oleh:

Michael Andreas Tjendra (231111210)

Diky Diwa Suwanto (231110760)

Enjel Boyzest Saragih (231111169)

PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN

2026

DAFTAR ISI

DAFTAR ISI....2
1. Perumusan Masalah....3
1.1 Latar belakang dan masalah....3
1.2 Tujuan....3
1.3 Target analisis....3
1.4 Batasan proyek....3
2. Dataset dan Pemahaman Data....4
2.1 Sumber dan akses....4
2.2 Struktur....4
2.3 Kualitas data....4
3. EDA dan Temuan Awal....6
4. Preprocessing....8
5. Feature Engineering Awal....9
6. Baseline Model....10
7. Model Kandidat Awal....10
8. Rancangan Evaluasi....11
8.1 Metrik dan alasan....11
8.2 Pemilihan jumlah klaster....12
8.3 Pengendalian risiko data leakage....13
8.4 Keterbatasan rancangan....13
9. Hasil dan Analisis Awal....13
Analisis sensitivitas jumlah klaster (k=3 sampai 5)....16
10. Dokumentasi dan Rencana Setelah UTS....16
10.1 Penelusuran berkas....16
10.2 Rencana pekerjaan setelah UTS....17
10.3 Kontribusi anggota....18
Referensi....18
Lampiran: Daftar Berkas Hasil Eksperimen....20

1. Perumusan Masalah

1.1 Latar belakang dan masalah

Profil media sosial siswa memuat banyak jejak minat, misalnya olahraga, musik, belanja, dan agama. Data seperti ini tidak berlabel, sehingga pengelompokan siswa berdasarkan kemiripan minat tidak bisa dikerjakan dengan klasifikasi. Masalah yang diangkat adalah: bagaimana mengelompokkan profil siswa ke dalam beberapa segmen berdasarkan pola minatnya, tanpa label, sehingga tiap segmen dapat dijelaskan secara ringkas dan masuk akal. Masalah ini penting karena segmentasi minat membantu memahami pola kelompok siswa tanpa harus membaca profil satu per satu, misalnya sebagai dasar merancang konten atau kegiatan yang relevan bagi tiap kelompok. Karena data tidak berlabel, pendekatan yang dipakai adalah unsupervised learning (clustering).

1.2 Tujuan

1. Memahami struktur, kualitas, sparsity, dan sebaran fitur pada dataset.
2. Menyiapkan representasi fitur yang sesuai untuk clustering.
3. Membandingkan beberapa algoritma clustering terhadap sebuah baseline secara konsisten.
4. Menafsirkan karakteristik tiap segmen memakai atribut profil (gender, usia, tahun kelulusan, jumlah teman).

1.3 Target analisis

Target analisis adalah sekumpulan segmen siswa beserta ringkasan profilnya. Karena tidak ada label kebenaran, keberhasilan pada tahap ini diukur dengan metrik internal (Silhouette, Davies-Bouldin, Calinski-Harabasz), ukuran klaster, dan kemudahan menafsirkan segmen. Keputusan model final belum diambil pada milestone ini.

1.4 Batasan proyek

- Input clustering hanya 36 fitur minat. Atribut profil (gradyear, gender, age, NumberOffriends) tidak dipakai untuk membentuk klaster dan hanya dipakai untuk menjelaskan hasil.
- Dataset tidak punya label kebenaran maupun ID siswa yang unik.
- Fitur minat berupa hitungan kemunculan kata kunci, sehingga nilai nol tidak selalu berarti siswa tidak punya minat.
- Hasil segmen bersifat agregat dan tidak boleh dipakai untuk menyimpulkan sifat individu.
- Tuning menyeluruh, pemilihan model final, analisis kesalahan lengkap, dan presentasi termasuk tahap lanjutan.

2. Dataset dan Pemahaman Data

2.1 Sumber dan akses

Dataset diambil dari Kaggle: *Students Social Network Profile Clustering* (https://www.kaggle.com/datasets/zabihullah18/students-social-network-profile-clustering). File yang dipakai bernama Clustering_Marketing.csv dan diletakkan di folder data/ (di Kaggle bernama 03_Clustering_Marketing.csv).

2.2 Struktur

Unit observasi adalah satu profil siswa (satu baris data). Dataset tidak memiliki variabel target, sehingga masalah ini ditangani sebagai clustering tanpa label.

Dataset berisi 15.000 profil siswa dan 40 kolom:

- **4 atribut profil:** gradyear, gender, age, NumberOffriends.
- **36 fitur minat:** bilangan bulat non-negatif yang menyatakan jumlah kemunculan kata kunci. Secara semantik terbagi menjadi olahraga (10), penampilan/romantis (8), musik (5), belanja/merek (5), religi (4), dan morbid/berisiko (4).

gradyear berkisar 2006-2009 dengan proporsi sekitar 25% per angkatan. Untuk gender, perempuan 73,7%, laki-laki 17,4%, dan kosong 8,9%.

Rincian kolom dataset per kelompok ditunjukkan pada tabel berikut. Setiap fitur minat berisi jumlah kemunculan kata kunci tersebut pada profil siswa.

Kelompok	Jumlah	Nama kolom
Olahraga	10	basketball, football, soccer, softball, volleyball, swimming, cheerleading, baseball, tennis, sports
Penampilan/romantis	8	cute, sex, sexy, hot, kissed, hair, dress, blonde
Musik	5	dance, band, marching, music, rock
Belanja/merek	5	mall, shopping, clothes, hollister, abercrombie
Religi	4	god, church, jesus, bible
Morbid/berisiko	4	die, death, drunk, drugs
Atribut profil (hanya interpretasi)	4	gradyear, gender, age, NumberOffriends

2.3 Kualitas data

Aspek	Temuan
Fitur minat	0 missing, 0 nilai negatif, semuanya bilangan bulat
gender	1.337 baris kosong (8,91%)
age	2.496 baris kosong (16,64%); 276 nilai berformat tanggal Jerman tanpa tahun (misalnya “16. Jun”); 153 nilai numerik di luar rentang 13-25 tahun, termasuk 77 nilai di atas 100 dengan maksimum 106,927

Aspek	Temuan
Baris duplikat penuh	266 baris salinan (1,77%), melibatkan 318 baris
Profil all-zero	1.238 profil (8,25%) tanpa minat tercatat
Sparsity	87,80% sel fitur minat bernilai nol; rata-rata 4,39 topik per profil

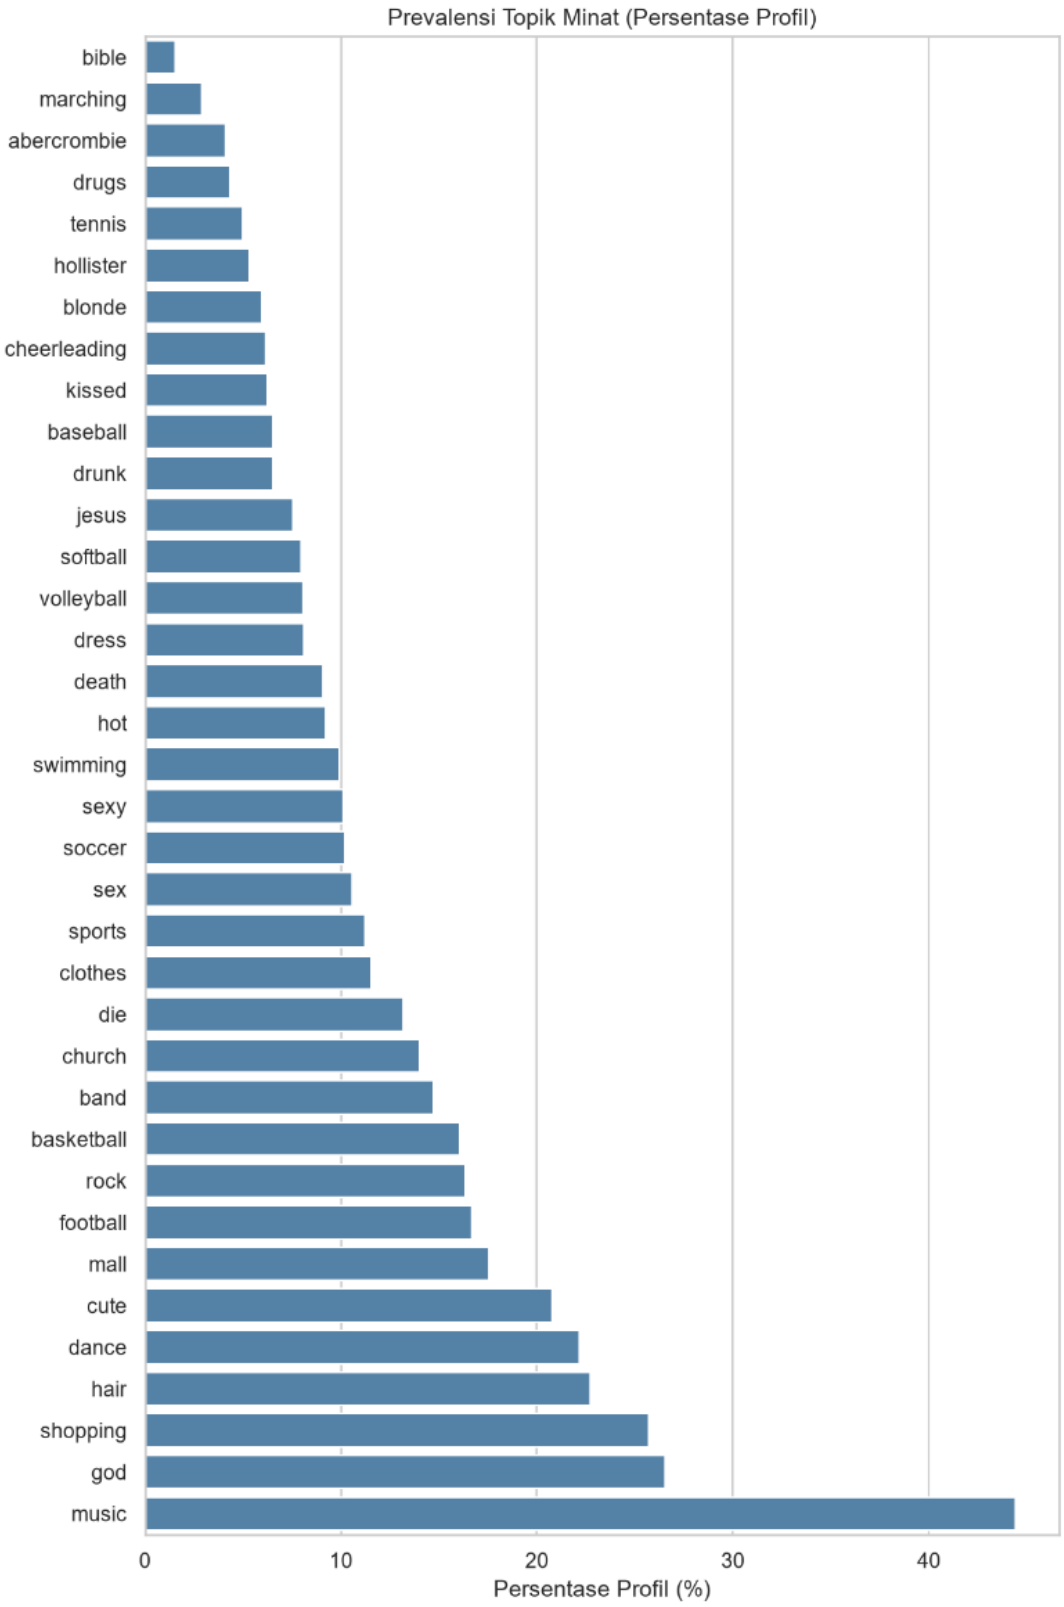
Setelah konversi dan penyaringan, 12.075 profil (80,5%) punya usia numerik dalam rentang 13-25 tahun. Artinya sekitar 19,5% usia (2.925 profil) tidak bisa dipakai langsung.

Di antara 318 baris yang terlibat duplikasi, 292 baris (91,8%) adalah profil kosong: 0 teman, gender dan usia tidak tercatat, serta nol pada seluruh 36 minat. Karena tidak ada ID siswa, kesamaan nilai ini lebih tepat dibaca sebagai profil yang tidak aktif mencatat minat, bukan kesalahan input ganda.

3. EDA dan Temuan Awal

Temuan	Bukti	Implikasi
Minat sangat jarang muncul	Seluruh fitur punya median 0; sparsity 87,80%	Jarak antar profil didominasi nol, sehingga perlu transformasi dan representasi alternatif
Distribusi sangat miring ke kanan	Semua fitur punya skewness di atas 2; blonde mencapai 117,25 dengan nilai maksimum 327	log1p dipakai untuk menekan nilai ekstrem tanpa membuang data
Nilai ekstrem nyata pada beberapa fitur	P99 blonde = 2 tetapi maksimum 327; P99 sex = 4, maksimum 114	Pemangkasan berbasis IQR tidak dipakai karena 33 dari 36 fitur punya IQR = 0
Topik terpopuler	Pada seluruh 15.000 profil: music 44,4%, god 26,5%, shopping 25,7%, hair 22,7%, dance 22,2%; terendah bible 1,5%	Fitur populer dan fitur langka perlu diseimbangkan lewat standardisasi
Korelasi positif antar topik yang berkaitan	band-marching 0,53; hollister-abercrombie 0,46; god-jesus 0,42	Struktur segmen kemungkinan ada, tetapi korelasinya sedang
Korelasi bergantung representasi	god-jesus turun dari 0,42 (count) menjadi 0,17 (biner)	Intensitas dan keberadaan minat membawa informasi berbeda, sehingga dua representasi diuji
Profil tanpa minat	1.238 profil all-zero; sekitar 18% profil punya 0 teman	Profil all-zero perlu diperlakukan terpisah
Distribusi teman miring ke kanan	Median 20, maksimum 605	NumberOffriends dipakai sebagai atribut interpretasi dengan statistik median

Temuan ini menjadi dasar keputusan preprocessing pada bagian berikutnya. Korelasi Pearson pada data yang sangat sparse perlu dibaca hati-hati, dan korelasi tidak menunjukkan sebab-akibat.

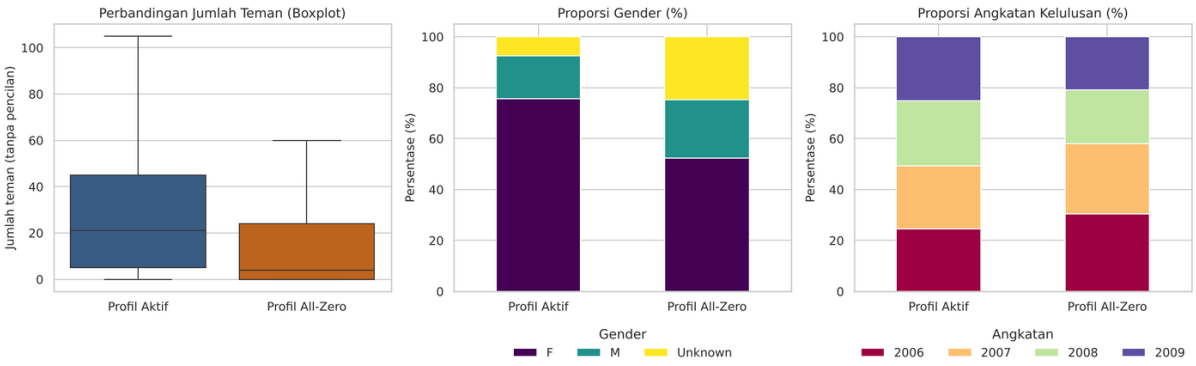


Gambar 1. Persentase profil yang menyebut tiap topik minat pada seluruh 15.000 profil. Music paling sering muncul, bible paling jarang.

4. Preprocessing

Langkah	Tindakan	Alasan
Pemisahan peran fitur	36 fitur minat sebagai input clustering; 4 atribut profil untuk interpretasi	Mencegah atribut demografis memengaruhi pembentukan klaster dan mencegah scale mismatch
gender kosong	Diisi kategori Unknown pada gender_clean	Semua baris tetap bisa dianalisis pada profiling
age tidak valid	Teks diubah dengan pd.to_numeric(errors='coerce'); nilai di luar 13-25 dijadikan NaN (age_clean)	Format tanggal tanpa tahun tidak bisa dipulihkan; usia ekstrem tidak masuk akal untuk siswa
age kosong	Diisi median per angkatan (age_imputed): 2006 = 18,68; 2007 = 17,70; 2008 = 16,74; 2009 = 15,79	Median usia turun sekitar satu tahun tiap angkatan; imputasi dipakai hanya untuk profiling
gradyear dan NumberOffriends	Divalidasi: gradyear bilangan bulat 2006-2009 tanpa kosong; NumberOffriends non-negatif	Tidak ada perbaikan yang diperlukan
Duplikat penuh	Tidak dihapus	Tanpa ID siswa, kesamaan nilai belum cukup untuk membuktikan duplikasi; 91,8% baris terlibat adalah profil kosong
Profil all-zero	1.238 profil dipisah sebagai Segmen 0, "No recorded interests"; clustering dijalankan pada 13.762 profil aktif	Pada ruang 36 dimensi profil ini berada di titik asal dan dapat menarik centroid serta membentuk klaster semu

Semua artefak hasil preprocessing disimpan di outputs/preprocessing/.



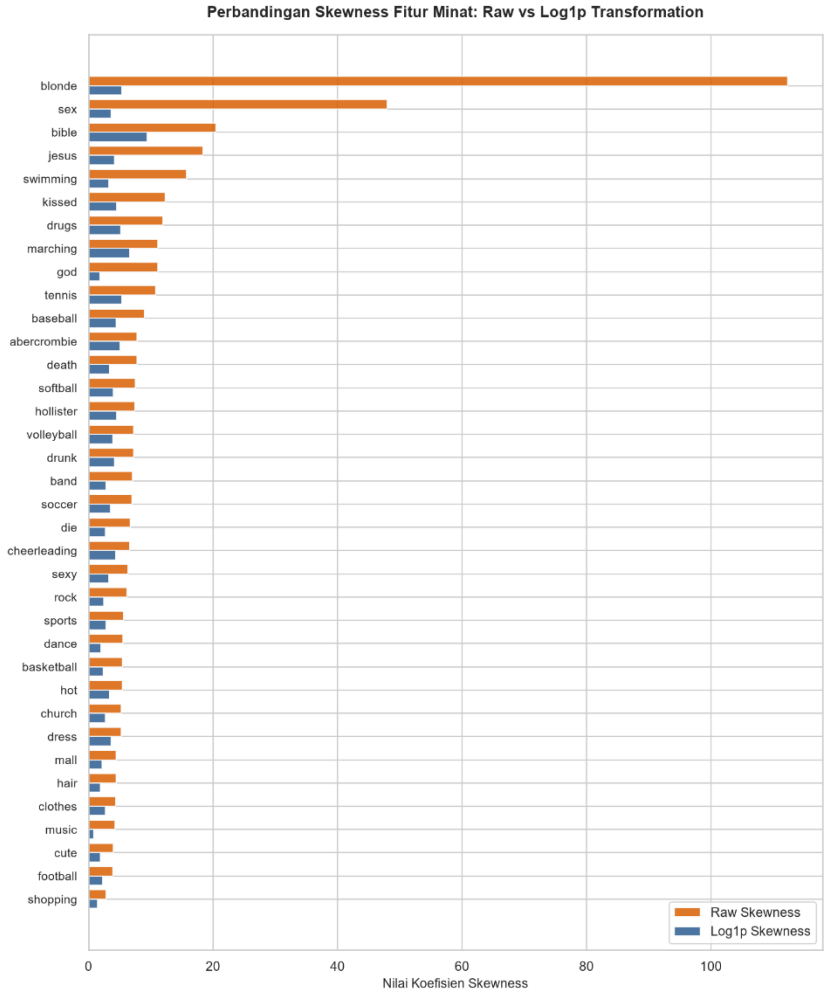
Gambar 2. Profil aktif dibandingkan profil all-zero: jumlah teman (tanpa pencilan), proporsi gender, dan proporsi angkatan. Profil all-zero punya lebih sedikit teman dan lebih banyak gender Unknown, sehingga layak dipisahkan.

5. Feature Engineering Awal

Dua representasi dibentuk dari 36 fitur minat pada profil aktif:

- **Representasi A (count):** transformasi log1p, lalu StandardScaler. Representasi ini mempertahankan informasi intensitas. Rata-rata skewness turun dari 11,86 menjadi 3,57 (turun 69,9%), dan skewness blonde turun dari 112,31 menjadi 5,35. Setelah standardisasi, setiap fitur bermean 0 dan std 1, sehingga fitur populer seperti music dan shopping tidak mendominasi jarak Euclidean.
- **Representasi B (biner):** nilai 1 jika hitungan lebih dari nol, selain itu 0. Representasi ini menangkap keberadaan minat tanpa memedulikan seberapa sering kata kunci diulang, yang berguna karena frekuensi bisa lebih mencerminkan kebiasaan mengetik atau keaktifan akun. Prevalensi biner pada profil aktif berkisar dari music 48,4% sampai bible 1,7%.

Atribut profil tidak ikut diubah menjadi fitur clustering. Seluruh proses terdokumentasi di notebooks/data_preparation.ipynb, dengan keluaran X_active_log1p_scaled.csv, X_active_binary.csv, dan scaler_active.joblib, serta statistik tiap fitur sebelum dan sesudah transformasi di outputs/tables/preprocessing_summary.csv.



Gambar 3. Skewness tiap fitur minat sebelum dan sesudah transformasi log1p.

6. Baseline Model

Baseline: K-Means pada Representasi A (log1p + scaled) dengan k=2, dijalankan pada 13.762 profil aktif.

K-Means dipilih sebagai baseline karena menjadi algoritma clustering paling dasar untuk data numerik, cepat dijalankan, dan menghasilkan penugasan klaster untuk profil baru. Nilai k=2 diambil dari pemilihan k pada bagian 8, bukan ditentukan sembarang.

Hasil baseline pada sampel evaluasi 2.500 profil aktif:

Metrik	Nilai
Silhouette	0,3025
Davies-Bouldin (lebih kecil lebih baik)	3,2524
Calinski-Harabasz	157,2216
Ukuran klaster terkecil	14,48%

Nilai Silhouette sekitar 0,30 menunjukkan struktur klaster yang lemah sampai sedang. Angka ini menjadi pembanding bagi semua kandidat.

7. Model Kandidat Awal

Alasan pemilihan kandidat:

- **K-Means (biner)** dipilih untuk menguji apakah keberadaan minat (ada atau tidak) menghasilkan segmen yang berbeda dari intensitas minat. Alasannya berasal dari EDA: korelasi god-jesus turun dari 0,42 pada data count menjadi 0,17 pada data biner, sehingga kedua representasi membawa informasi yang berbeda.
- **Agglomerative Ward** dipilih karena tidak bergantung pada inisialisasi acak dan membentuk hierarki, sehingga bisa memperlihatkan apakah data punya struktur bertingkat. Kriteria Ward meminimalkan variansi dalam klaster, sama seperti K-Means, sehingga hasil keduanya dapat dibandingkan secara langsung.
- **DBSCAN** dipilih karena berbasis kepadatan, tidak memerlukan jumlah klaster di awal, dan dapat menandai profil yang tidak masuk kelompok mana pun sebagai noise. Sifat ini relevan karena data sangat sparse dan memiliki banyak nilai ekstrem.
- **Gaussian Mixture** dipilih sebagai pembanding asumsi K-Means. GMM memberi keanggotaan probabilistik dan memungkinkan klaster berbentuk elips. Kovarians diagonal dipakai agar jumlah parameter tetap kecil pada 36 dimensi.

Empat kandidat dibandingkan dengan baseline pada sampel deterministik yang sama, yaitu 2.500 profil aktif:

Model	Klaster (noise)	Silhouette	Davies-Bouldin	Calinski-Harabasz	Klaster terkecil	Metode validasi
Baseline: K-Means (log1p-scaled)	2 (0%)	0,3025	3,2524	157,2216	14,48%	Metrik internal, 2.500 profil
K-Means (biner)	2 (0%)	0,1652	4,0514	127,1706	29,64%	Metrik internal, 2.500 profil
Agglomerative Ward	2 (0%)	0,4493	1,9042	99,9252	2,12%	Metrik internal, 2.500 profil
DBSCAN (eps=1,37; min_samples=10)	14 (88,00%)	0,6268*	0,5828*	109,0548*	3,67%*	Metrik internal, 300 inlier*
Gaussian Mixture (diagonal, log1p-scaled)	2 (0%)	0,2402	3,9331	117,9022	18,72%	Metrik internal, 2.500 profil

**DBSCAN hanya dihitung pada 300 inlier dari 2.500 profil; 2.200 profil (88,00%) menjadi noise. Skor tinggi berasal dari subset kecil yang sangat rapat dan tidak mewakili populasi. Nilai eps dibulatkan ke atas dari titik knee (1,3633 menjadi 1,37) karena pada nilai knee hasil DBSCAN berubah antar komputer.* Kolom "Metode validasi": tidak ada pemisahan data latih dan uji karena data tidak berlabel; semua model dinilai dengan metrik internal pada sampel deterministik yang sama.

Pembacaan terhadap baseline:

- **K-Means biner** lebih buruk dari baseline pada Silhouette, Davies-Bouldin, dan Calinski-Harabasz. Semua kandidat, termasuk model biner ini, dinilai pada ruang log1p-scaled dan sampel yang sama, sehingga perbandingannya setara. Ruang itu juga menguntungkan model yang dilatih di dalamnya, jadi selisihnya perlu dibaca hati-hati.
- **Agglomerative Ward** unggul pada Silhouette dan Davies-Bouldin, tetapi klaster terkecilnya hanya 2,12% dan Calinski-Harabasz-nya lebih rendah dari baseline. Estimator ini juga tidak menyediakan prediksi langsung untuk profil baru, sehingga dipertahankan sebagai pembanding eksploratif.
- **GMM** lebih buruk dari baseline pada ketiga metrik.
- **DBSCAN** menandai hampir seluruh profil sebagai noise dan tidak cocok dengan parameter yang diuji.

Berdasarkan perbandingan ini, K-Means pada Representasi A tetap menjadi **kandidat terbaik sementara**. Sebutan ini bukan keputusan model final.

8. Rancangan Evaluasi

8.1 Metrik dan alasan

Karena tidak ada label, evaluasi memakai metrik internal: Silhouette (kohesi dan pemisahan), Davies-Bouldin (kemiripan antar klaster), Calinski-Harabasz (rasio sebaran antar dan dalam klaster), serta inertia untuk metode siku. Selain metrik, dipertimbangkan ukuran klaster terkecil

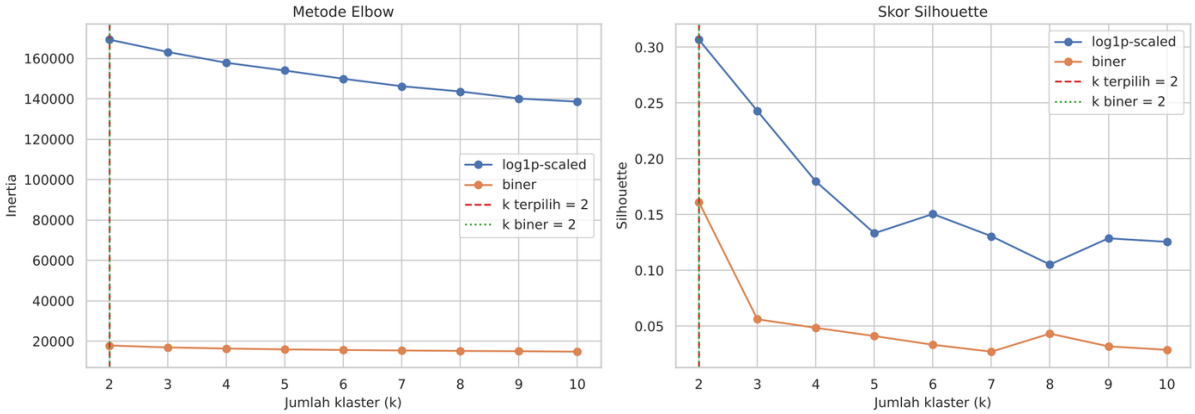
dan kemudahan menafsirkan segmen. Tidak ada pemisahan data latih dan uji karena tidak ada label sebagai acuan. Metode validasinya adalah penilaian metrik internal pada sampel deterministik yang sama untuk semua model (2.500 profil aktif), sedangkan uji kestabilan antar seed dan antar subsampel dijadwalkan pada rencana lanjutan (bagian 10.2). Rujukan algoritma dan metrik ada di bagian Referensi.

8.2 Pemilihan jumlah klaster

K-Means diuji pada k=2 sampai k=10 untuk kedua representasi. Silhouette untuk pemilihan k dihitung pada subsampel 2.000 dari maksimal 5.000 profil. Aturan tambahan: klaster terkecil sebaiknya tidak di bawah 2% populasi.

k	Silhouette (log1p)	Klaster terkecil (log1p)	Silhouette (biner)	Klaster terkecil (biner)
2	0,3068	13,38%	0,1613	28,74%
3	0,2429	3,34%	0,0561	18,70%
4	0,1796	3,36%	0,0485	14,76%
5	0,1333	3,34%	0,0411	11,28%
6	0,1505	3,30%	0,0333	9,94%
7	0,1306	3,32%	0,0271	9,32%
8	0,1052	3,30%	0,0433	5,72%
9	0,1287	1,40%	0,0319	5,72%
10	0,1256	1,42%	0,0287	5,00%

Silhouette tertinggi ada pada k=2 untuk kedua representasi. Inertia K-Means pada log1p turun perlahan dari 169.280 (k=2) ke 138.570 (k=10), tanpa siku yang tegas. Nilai Silhouette pada tabel ini berbeda dari tabel bagian 7 karena sampelnya berbeda. Untuk model biner ada alasan kedua: Silhouette di sini dihitung pada ruang biner, sedangkan tabel bagian 7 menilai semua model pada ruang log1p-scaled.



Gambar 4. Inertia dan Silhouette K-Means untuk k=2 sampai 10 pada representasi log1p-scaled dan biner. Silhouette tertinggi ada pada k=2 untuk keduanya.

8.3 Pengendalian risiko data leakage

- Atribut profil (gender, age, gradyear, NumberOffriends) dikeluarkan dari input clustering dan hanya dipakai sesudah label terbentuk.
- Profil all-zero dipisahkan sebelum pemodelan, dan Segmen 0 tidak dianggap sebagai prediksi K-Means.
- Semua kandidat dibandingkan pada sampel yang sama dan deterministik.
- Karena tidak ada label target, tidak ada pemisahan data latih dan uji seperti pada klasifikasi. Risiko yang relevan adalah kebocoran lewat fitur dan pemilihan model berdasarkan sampel yang sama. Pemeriksaan kestabilan pada sampel lain dijadwalkan pada rencana lanjutan.

8.4 Keterbatasan rancangan

Metrik masih internal dan dihitung pada subsampel. Belum ada uji kestabilan, dan metrik untuk model final pada seluruh 13.762 profil belum dilaporkan. Hal-hal ini masuk rencana pada bagian 10.

9. Hasil dan Analisis Awal

Model K-Means final sementara di-fit pada seluruh 13.762 profil aktif. Profil all-zero dipertahankan sebagai cluster_id=0.

Klaster	Jumlah	Proporsi dari 15.000	Profil ringkas
0	1.238	8,25%	Tidak ada minat tercatat; median teman 4; usia imputasi rata-rata 17,40
1	11.523	76,82%	Rata-rata hitungan tertinggi pada music, god, dance; median total minat 5; median 20 teman; usia imputasi rata-rata 17,28
2	2.239	14,93%	Rata-rata hitungan tertinggi pada hair, music, god; median total minat 16; median 27 teman; usia imputasi rata-rata 17,00

Komposisi gender (perempuan/laki-laki/Unknown): klaster 0 = 52,3% / 23,0% / 24,7%; klaster 1 = 73,5% / 18,6% / 7,9%; klaster 2 = 86,7% / 7,9% / 5,4%.

Arti tiap klaster (nama segmen bersifat sementara dan dipakai untuk membaca hasil):

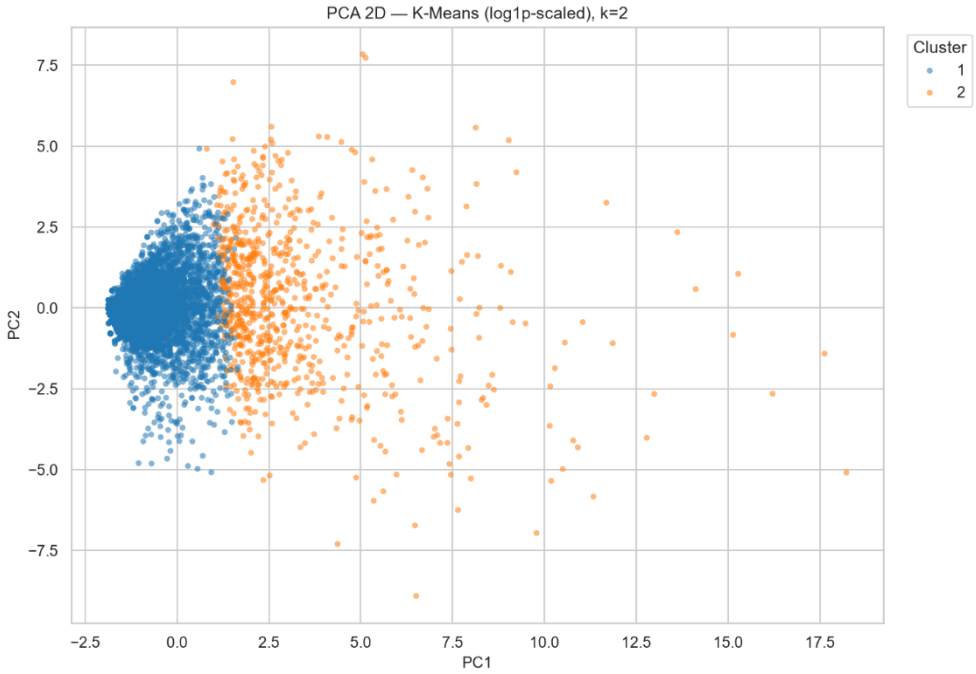
Klaster	Jumlah	Ciri yang terlihat	Arti
0: Tanpa minat tercatat	1.238 (8,25%)	Seluruh 36 fitur bernilai 0; median teman 4; gender Unknown 24,7%	Profil yang tidak menuliskan kata kunci minat apa pun, bisa karena akun pasif atau profil tidak diisi. Bukan berarti siswanya tidak punya minat.
1: Minat sedikit sampai sedang	11.523 (76,82%)	Median total minat 5; median teman 20; topik tertinggi music, god, dance	Kelompok mayoritas tanpa topik yang menonjol. Topik yang sering muncul sama dengan topik paling umum di seluruh data.
2: Minat banyak (profil aktif)	2.239 (14,93%)	Median total minat 16; median teman 27; perempuan 86,7%; rata-rata hitungan lebih tinggi daripada klaster 1 pada semua 36 topik (1,8 sampai 20,4 kali), terbesar pada kissed, drugs, blonde	Siswa yang menulis banyak minat di profilnya. Klaster ini dibedakan oleh banyaknya minat, bukan oleh satu topik khusus.

Jadi ketiga segmen dapat dibaca sebagai tiga tingkat banyaknya minat yang tercatat: tidak ada, sedang, dan banyak. Perbedaan jumlah teman dan komposisi gender hanya gambaran deskriptif dan tidak menunjukkan hubungan sebab-akibat. Perbandingan 36 topik antar klaster dihitung di notebooks/model_development.ipynb, tepat setelah tabel komposisi gender.

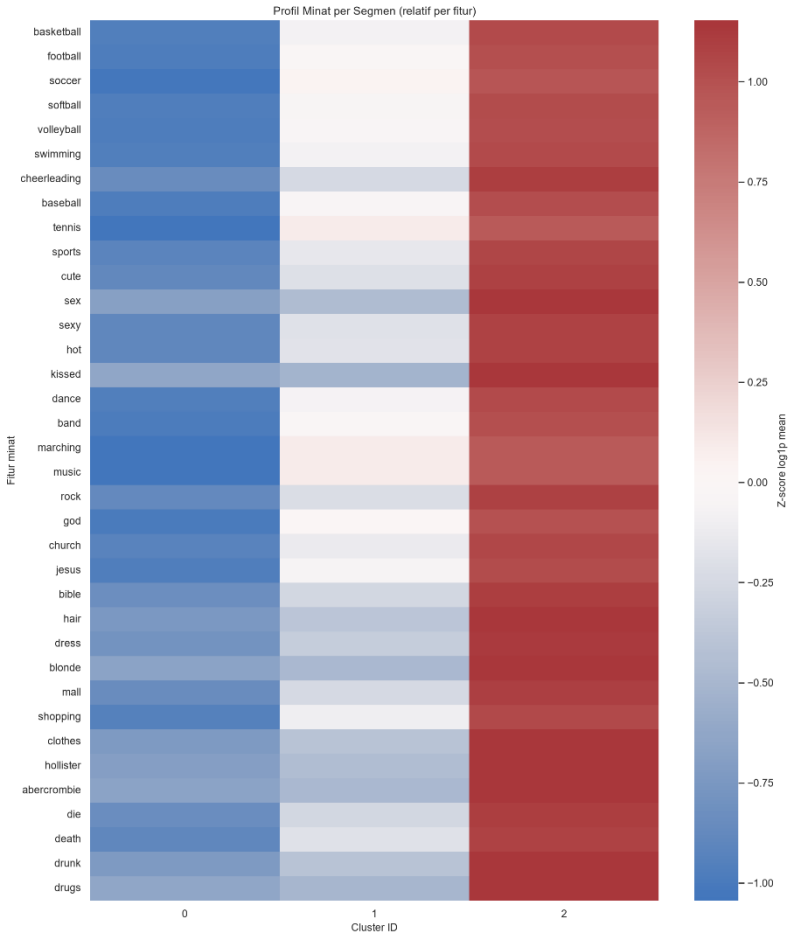
Interpretasi awal:

- Klaster 2 berisi siswa dengan jumlah minat tercatat lebih banyak (median total 16 dibanding 5) dan lebih banyak teman. Perbedaannya lebih terlihat pada intensitas dan keaktifan profil daripada pada topik yang sama sekali berbeda, karena music dan god muncul di kedua klaster.
- Klaster 1 menampung mayoritas (76,82%), sehingga segmentasi dua klaster tergolong kasar.
- Perbedaan usia antar klaster kecil (17,00 sampai 17,40). Karena sekitar 19,5% usia diimputasi dengan median angkatan, perbedaan ini sebagian besar mencerminkan komposisi gradyear dan tidak boleh dianggap temuan kuat.
- PCA dua komponen hanya menjelaskan 14,46% variansi, sehingga plot PCA dipakai untuk visualisasi dan bukan bukti pemisahan yang kuat.

Sebaran PCA (Gambar 5) memperlihatkan satu gumpalan padat yang terpotong sepanjang PC1, bukan dua kelompok yang terpisah. Heatmap profil minat (Gambar 6) menunjukkan klaster 2 lebih tinggi pada hampir semua fitur, klaster 0 paling rendah, dan klaster 1 di antaranya. Jadi segmen yang terbentuk terutama mencerminkan tingkat keaktifan (total minat tercatat), bukan perbedaan jenis minat. Temuan ini menjadi masukan utama untuk rencana lanjutan.



Gambar 5. Proyeksi PCA dua komponen untuk K-Means (log1p-scaled, k=2) pada sampel hingga 5.000 profil. Kedua klaster tidak terpisah tegas. Klaster 0 (profil all-zero) tidak diplot karena tidak ikut clustering.



Gambar 6. Profil minat per segmen, berupa z-score relatif per fitur dari rata-rata log1p.

Analisis sensitivitas jumlah klaster (k=3 sampai 5)

Pembagian k=2 berkorelasi sekitar 0,63 dengan total minat per profil (median total minat 5 pada klaster 1 dan 16 pada klaster 2), jadi pembagian itu memang terutama memisahkan keaktifan. Untuk melihat apakah ada struktur topik di baliknya, K-Means dijalankan juga pada k=3, 4, dan 5 dengan representasi yang sama (notebooks/model_development.ipynb bagian 8; tabel lengkap di outputs/tables/k_sensitivity_profiles.csv). Ringkasannya, dengan nama sementara pada kolom pertama yang menjelaskan arti tiap kelompok:

Kelompok	Fitur dengan rata-rata z-score tertinggi	Ukuran pada k=3 / k=4 / k=5	Median total minat
Minat sedikit, tanpa fitur menonjol (kelompok umum)	z-score tertinggi mendekati 0	69,5% / 67,5% / 63,4%	4
Campuran: belanja, religi, dan hal-hal cute	shopping, church, cute, hollister	24,9% / 24,0% / tidak ada	12
Romantis, penampilan, dan topik berisiko (kissed-sex-drugs-hair)	kissed, sex, drugs, hair	5,5% / 5,5% / 5,4%	20 sampai 21
Musik dan marching band (marching-band-music-rock)	marching, band, music, rock	tidak ada / 3,0% / 3,0%	10
Belanja dan merek pakaian	hollister, abercrombie, shopping, mall	tidak ada / tidak ada / 5,6%	11
Religi dan olahraga	church, football, basketball, god	tidak ada / tidak ada / 22,5%	11

Dua kelompok kecil (kissed-sex-drugs-hair dan marching-band-music-rock) muncul pada semua nilai k yang memuatnya dengan ukuran hampir sama, sedangkan kelompok belanja dan merek serta kelompok religi dan olahraga baru terpisah pada k=5. Kelompok-kelompok ini kecil dan saling tumpang tindih, sehingga Silhouette-nya lebih rendah daripada k=2. Hasil ini berasal dari satu kali fit (random_state=42) dan belum diuji kestabilannya.

Kesimpulan awal: struktur klaster yang ditemukan lemah sampai sedang, dan dua klaster belum memberi segmentasi yang kaya. Analisis k=3 sampai 5 menunjukkan ada kelompok topik kecil di balik pembagian kasar ini. Temuan ini menjadi alasan utama rencana lanjutan.

10. Dokumentasi dan Rencana Setelah UTS

10.1 Penelusuran berkas

Komponen rubrik	Bagian laporan	Artefak
Perumusan masalah	1	README.md
Dataset dan pemahaman data	2	data/Clustering_Marketing.csv, notebooks/eda_data_understanding.ipynb
EDA	3	outputs/EDA/figures/*.png, outputs/EDA/*.csv
Preprocessing	4	notebooks/data_preparation.ipynb, outputs/preprocessing/, outputs/tables/preprocessing_summary.csv

Komponen rubrik	Bagian laporan	Artefak
Feature engineering	5	X_active_log1p_scaled.csv, X_active_binary.csv, scaler_active.joblib
Baseline dan kandidat	6 dan 7	notebooks/model_development.ipynb, outputs/tables/model_comparison.csv
Rancangan evaluasi	8	outputs/tables/k_selection_metrics.csv, outputs/figures/kmeans_k_selection.png
Hasil dan analisis	9	cluster_profile_summary.csv, cluster_gender_profile.csv, clustered_student_profiles.csv, k_sensitivity_profiles.csv, outputs/models/best_clustering_model.joblib

Cara menjalankan lengkap (instalasi paket, urutan notebook, serta penggunaan di Colab atau Kaggle) ada di README.md. Ringkasnya: pasang paket dari requirements.txt (atau requirements-lock.txt), letakkan dataset di data/, lalu jalankan eda_data_understanding, data_preparation, dan model_development secara berurutan.

10.2 Rencana pekerjaan setelah UTS

Rencana disusun dari kekurangan yang tercatat pada bagian 8 dan 9.

No	Pekerjaan	Alasan dari temuan awal
1	Uji kestabilan segmen: bandingkan label antar seed dan antar subsampel dengan Adjusted Rand Index	Belum ada bukti kestabilan; metrik hanya dari satu sampel
2	Laporkan metrik model final pada seluruh 13.762 profil	Metrik saat ini berasal dari subsampel
3	Perdalam analisis k=3 sampai 5 (kestabilan kelompok kecil dan penamaan segmen), bukan hanya Silhouette	Pada k=3 sampai 5 muncul kelompok topik kecil (3% sampai 6%) yang belum diuji kestabilannya
4	Tuning terbatas: jumlah inisialisasi, eps DBSCAN, jenis kovarians GMM, linkage hierarkis	Perbandingan awal memakai pengaturan tunggal untuk tiap model
5	Bandingkan hasil dengan dan tanpa baris duplikat	Tidak ada ID siswa, dan EDA merekomendasikan pembandingan ini
6	Uji kepekaan terhadap imputasi usia, misalnya profiling hanya pada usia valid	Sekitar 19,5% usia diimputasi sehingga tafsir usia lemah
7	Validasi domain atas profil segmen dan analisis kesalahan	Tanpa label, kualitas segmen perlu diperiksa dengan penilaian manual
8	Uji representasi yang menghilangkan efek total minat per profil (misalnya normalisasi baris atau jarak cosine pada data biner), lalu bandingkan segmen yang terbentuk	Heatmap dan PCA menunjukkan segmen k=2 terutama membedakan tingkat keaktifan, bukan jenis minat
9	Pilih model final, siapkan presentasi dan tanya jawab	Tahap lanjutan sesuai ketentuan rubrik

10.3 Kontribusi anggota

Pembagian tanggung jawab utama tiap anggota. Setiap anggota memahami bagian yang dikerjakannya dan ikut meninjau seluruh laporan.

Anggota (NIM)	Pembagian Tugas	Notebook
Michael Andreas Tjendra (231111210)	Mengeksplorasi data, mulai dari struktur, kualitas, sebaran, hingga hubungan antarfitur.	`eda_data_understanding.ipynb`
Diky Diwa Suwanto (231110760)	Pengembangan model, mulai dari membuat baseline, mencoba beberapa model, menentukan nilai k terbaik, mengevaluasi hasil, hingga menganalisis dan mengelompokkan data.	`model_development.ipynb`
Enjel Boyzest Saragih (231111169)	Persiapan data, mulai dari membersihkan data gender dan usia, mengisi data yang kosong, memisahkan profil all-zero, hingga melakukan transformasi dan standardisasi data agar siap digunakan untuk pemodelan.	`data_preparation.ipynb`

Referensi

Arthur, D., & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms*, 1027–1035.

Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics, 3*(1), 1–27.

Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224–227.

Dempster, A. P., Laird, N. M., & Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B, 39*(1), 1–22.

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 226–231.

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218.

Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory, 28*(2), 129–136.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65.

Thorndike, R. L. (1953). Who belongs in the family? *Psychometrika, 18*(4), 267–276.

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244.

zabihullah18. (t.t.). *Students Social Network Profile Clustering* [Dataset]. Kaggle. https://www.kaggle.com/datasets/zabihullah18/students-social-network-profile-clustering

Lampiran: Daftar Berkas Hasil Eksperimen

Semua berkas di bawah ada di folder outputs/ yang ikut dikumpulkan. Tabel dan gambar yang menopang klaim utama sudah ditampilkan di bagian laporan yang tercantum pada kolom terakhir atau sebagai nomor gambar.

A. Tabel hasil eksperimen

Berkas	Isi	Bagian
outputs/tables/model_comparison.csv	Perbandingan baseline dan 4 kandidat (5 baris, 10 kolom)	7
outputs/tables/k_selection_metrics.csv	Inertia, Silhouette, dan ukuran klaster terkecil untuk k=2 sampai 10 pada dua representasi (9 baris, 7 kolom)	8.2
outputs/tables/k_sensitivity_profiles.csv	Profil klaster pada k=3, 4, dan 5 (12 baris, 7 kolom)	9
outputs/tables/cluster_profile_summary.csv	Profil tiga segmen: ukuran, atribut profil, rata-rata dan median tiap fitur (3 baris, 84 kolom)	9
outputs/tables/cluster_gender_profile.csv	Komposisi gender tiap segmen (3 baris, 4 kolom)	9
outputs/tables/clustered_student_profiles.csv	Label klaster dan atribut tiap profil (15.000 baris, 47 kolom)	9
outputs/tables/preprocessing_summary.csv	Statistik tiap fitur minat sebelum dan sesudah transformasi: rata-rata, maksimum, skewness, prevalensi biner (36 baris, 8 kolom)	5

B. Gambar

Gambar	Berkas
Gambar 1	outputs/EDA/figures/topic_prevalence.png
Gambar 2	outputs/figures/all_zero_profile_comparison.png
Gambar 3	outputs/figures/skewness_comparison.png
Gambar 4	outputs/figures/kmeans_k_selection.png
Gambar 5	outputs/figures/best_model_pca_clusters.png
Gambar 6	outputs/figures/cluster_interest_heatmap.png

Gambar dan tabel lain di folder outputs/ (misalnya hasil EDA di outputs/EDA/) adalah bukti pendukung yang dihasilkan notebook dan tidak ditampilkan di laporan.